



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ (ИУ5)

## О Т Ч Е Т

### по лабораторной работе

по дисциплине: Технологии машинного обучения

на тему: Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных

Студент ИУ5-62Б  
(Группа)

\_\_\_\_\_  
(Подпись, дата)

Е.О. Белова  
(И.О.Фамилия)

Руководитель

\_\_\_\_\_  
(Подпись, дата)

Ю.Е. Гапанюк  
(И.О.Фамилия)

2020 г.

# Лабораторная работа №3

## Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных

### Цель лабораторной работы

#### Задание

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
  - обработку пропусков в данных;
  - кодирование категориальных признаков;
  - масштабирование данных.

```
In [140]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

### Загрузка данных

Ссылка на датасет: <https://www.kaggle.com/fivethirtyeight/fivethirtyeight-comic-characters-dataset>

```
In [192]: data = pd.read_csv('data/marvel-wikia-data.csv', sep=",")
data.head()
```

Out[192]:

	page_id	name	urlslug	ID	ALIGN	EYE	HAIR
0	1678	Spider-Man (Peter Parker)	VSpider-Man_(Peter_Parker)	Secret Identity	Good Characters	Hazel Eyes	Brown Hair
		Captain America		Public	Good	Blue	White

1	7139	(Steven Rogers)	VCaptain_America_(Steven_Rogers)	Identity	Characters	Eyes	Hair
2	64786	Wolverine (James "Logan" Howlett)	VWolverine_(James_%22Logan%22_Howlett)	Public Identity	Neutral Characters	Blue Eyes	Black Hair
3	1868	Iron Man (Anthony "Tony" Stark)	VIron_Man_(Anthony_%22Tony%22_Stark)	Public Identity	Good Characters	Blue Eyes	Black Hair
4	2460	Thor (Thor Odinson)	VThor_(Thor_Odinson)	No Dual Identity	Good Characters	Blue Eyes	Blond Hair

```
In [142]: # размер набора данных
data.shape
```

```
Out[142]: (16376, 13)
```

```
In [143]: # типы колонок
data.dtypes
```

```
Out[143]: page_id      int64
name                object
urlslug            object
ID                 object
ALIGN              object
EYE                object
HAIR               object
SEX                object
GSM                object
ALIVE              object
APPEARANCES        float64
FIRST APPEARANCE   object
Year               float64
dtype: object
```

```
In [144]: # проверим есть ли пропущенные значения
data.isnull().sum()
```

```
Out[144]: page_id      0
name                0
urlslug            0
ID                 3770
ALIGN              2812
EYE                9767
HAIR               4264
SEX                854
GSM                16286
ALIVE              3
APPEARANCES        1096
FIRST APPEARANCE   815
Year               815
dtype: int64
```

```
In [146]: total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

# 1. Обработка пропусков в данных

## Простые стратегии: удаление

```
In [147]: data = data.dropna(axis=1, thresh=int(data.shape[0] * 0.49))
```

```
In [148]: data.isnull().sum()
```

```
Out[148]: page_id      0
name              0
urlslug          0
ID              3770
ALIGN           2812
HAIR            4264
SEX             854
ALIVE           3
APPEARANCES     1096
FIRST APPEARANCE 815
Year            815
dtype: int64
```

```
In [149]: data[data['ALIVE'].isnull()]
```

```
Out[149]:
```

	page_id	name	urlslug	ID	ALIGN	HAIR	SEX	ALIVE	APPEARANCES
<b>16293</b>	541449	Mj7711	VUser:Mj7711	NaN	NaN	NaN	NaN	NaN	NaN
<b>16329</b>	714409	Sharjeel786	VUser:Sharjeel786	NaN	NaN	NaN	NaN	NaN	NaN
<b>16347</b>	462671	TORV/test	VUser:TORV/test	NaN	NaN	NaN	NaN	NaN	NaN

```
In [150]: # Удаление 3 строк
data = data.drop(data.index[[16293,16329,16347]])
```

```
In [151]: data.isnull().sum()
```

```
Out[151]: page_id      0
name              0
urlslug          0
ID              3767
ALIGN           2809
HAIR            4261
SEX             851
ALIVE           0
APPEARANCES     1093
FIRST APPEARANCE 812
Year            812
dtype: int64
```

# "Внедрение значений" - импьютация (imputation)

## Обработка пропусков в числовых данных

```
In [152]: # Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count > 0 and (dt == 'float64' or dt == 'int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка { }. Тип данных { }. Количество пустых значений { }, { }%'.format(col, dt, temp_n
ull_count, temp_perc))
```

Колонка APPEARANCES. Тип данных float64. Количество пустых значений 1093, 6.67%.

Колонка Year. Тип данных float64. Количество пустых значений 812, 4.96%.

```
In [153]: # Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[153]:



	APPEARANCES	Year
0	4043.0	1962.0
1	3360.0	1941.0
2	3061.0	1974.0
3	2961.0	1963.0
4	2258.0	1950.0
...	...	...
16371	NaN	NaN
16372	NaN	NaN
16373	NaN	NaN
16374	NaN	NaN
16375	NaN	NaN

16373 rows × 2 columns

```
In [154]: # Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

```
c:\users\user\appdata\local\programs\python\python37-32\lib\site-package
s\numpy\lib\histograms.py:839: RuntimeWarning: invalid value encountered
in greater_equal
    keep = (tmp_a >= first_edge)
c:\users\user\appdata\local\programs\python\python37-32\lib\site-package
```

```
s\numpy\lib\histograms.py:840: RuntimeWarning: invalid value encountered
in less_equal
keep &= (tmp_a <= last_edge)
```



```
In [155]: # Фильтр по пустым значениям поля APPEARANCES
data[data['APPEARANCES'].isnull()]
```

Out[155]:

	page_id	name	urlslug	ID	ALIGN	HAIR	SEX
15280	743309	Minister of Castile D'or (Earth-616)	VMinister_of_Castile_D%27or_(Earth-616)	No Dual Identity	Neutral Characters	NaN	Male Character
15281	645438	Mr. Harris' Secretary (Earth-616)	VMr._Harris%27_Secretary_(Earth-616)	No Dual Identity	Neutral Characters	Blond Hair	Female Character
15282	331151	N'Jaga (Earth-616)	VN%27Jaga_(Earth-616)	No Dual Identity	Bad Characters	NaN	Male Character
15283	505986	Ertve (Earth-616)	VErtve_(Earth-616)	Secret Identity	Good Characters	White Hair	Male Character
15284	19657	Invisible Man (Gade) (Earth-616)	VInvisible_Man_(Gade)_(Earth-616)	Secret Identity	Good Characters	NaN	Male Character



<b>16371</b>	657508	Ru'ach (Earth-616)	VRu%27ach_(Earth-616)	Dual Identity	Bad Characters	No Hair	Mal Character
<b>16372</b>	665474	Thane (Thanos' son) (Earth-616)	VThane_(Thanos%27_son)_(Earth- 616)	No Dual Identity	Good Characters	Bald	Mal Character
<b>16373</b>	695217	Tinkerer (Skrull) (Earth-616)	VTinkerer_(Skrull)_(Earth-616)	Secret Identity	Bad Characters	Bald	Mal Character
<b>16374</b>	708811	TK421 (Spiderling) (Earth-616)	VTK421_(Spiderling)_(Earth-616)	Secret Identity	Neutral Characters	NaN	Mal Character
<b>16375</b>	673702	Yologarch (Earth-616)	VYologarch_(Earth-616)	NaN	Bad Characters	NaN	NaN

1093 rows × 11 columns

```
In [158]: # фильтр по колонке
data_num[data_num.index.isin(flt_index)]['APPEARANCES']
```

```
Out[158]: 15280 NaN
15281 NaN
15282 NaN
15283 NaN
15284 NaN
..
16371 NaN
16372 NaN
16373 NaN
16374 NaN
16375 NaN
Name: APPEARANCES, Length: 1093, dtype: float64
```

```
In [159]: data_num_APPEARANCES = data_num[['APPEARANCES']]
data_num_APPEARANCES.head()
```

```
Out[159]:
```

APPEARANCES	
0	4043.0
1	3360.0
2	3061.0
3	2961.0
4	2258.0

```
In [160]: from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

```
In [161]: # Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_APPEARANCES)
mask_missing_values_only
```

```
Out[161]: array([[False],
```



```
[False],
[False],
...,
[ True],
[ True],
[ True]])
```

```
In [162]: strategies=['mean', 'median', 'most_frequent']
```

```
In [163]: def test_num_impute(strategy_param):
            imp_num = SimpleImputer(strategy=strategy_param)
            data_num_imp = imp_num.fit_transform(data_num_APPEARANCES)
            return data_num_imp[mask_missing_values_only]
```

```
In [164]: strategies[0], test_num_impute(strategies[0])
```

```
Out[164]: ('mean',
array([17.03337696, 17.03337696, 17.03337696, ..., 17.03337696,
       17.03337696, 17.03337696]))
```

```
In [165]: strategies[1], test_num_impute(strategies[1])
```

```
Out[165]: ('median', array([3., 3., 3., ..., 3., 3., 3.]))
```

```
In [166]: strategies[2], test_num_impute(strategies[2])
```

```
Out[166]: ('most_frequent', array([1., 1., 1., ..., 1., 1., 1.]))
```

Заменим все пустые данные столбца 'APPEARANCES' на данные  
test\_num\_impute(strategies[2])

```
In [167]: new_APPEARANCES = pd.DataFrame({'id': flt_index,
            'APPEARANCES': test_num_impute(strategies[2])})
new_APPEARANCES
```

```
Out[167]:
```

	id	APPEARANCES
0	15280	1.0
1	15281	1.0
2	15282	1.0
3	15283	1.0
4	15284	1.0
...	...	...
1088	16371	1.0
1089	16372	1.0
1090	16373	1.0
1091	16374	1.0
1092	16375	1.0

1093 rows × 2 columns

```
In [168]: for index, row in new_APPEARANCES.iterrows():
          data.loc[row['id'], 'APPEARANCES'] = row['APPEARANCES']
          data
```

Out[168]:

	page_id	name	urlslug	ID	ALIGN	HAIR	
0	1678	Spider-Man (Peter Parker)	VSpider-Man_(Peter_Parker)	Secret Identity	Good Characters	Brown Hair	C
1	7139	Captain America (Steven Rogers)	VCaptain_America_(Steven_Rogers)	Public Identity	Good Characters	White Hair	C
2	64786	Wolverine (James \"Logan\" Howlett)	VWolverine_(James_%22Logan%22_Howlett)	Public Identity	Neutral Characters	Black Hair	C
3	1868	Iron Man (Anthony \"Tony\" Stark)	VIron_Man_(Anthony_%22Tony%22_Stark)	Public Identity	Good Characters	Black Hair	C
4	2460	Thor (Thor Odinson)	VThor_(Thor_Odinson)	No Dual Identity	Good Characters	Blond Hair	C
...	...	...	...	...	...	...	...
16371	657508	Ru'ach (Earth-616)	VRu%27ach_(Earth-616)	No Dual Identity	Bad Characters	No Hair	C
16372	665474	Thane (Thanos' son) (Earth-616)	VThane_(Thanos%27_son)_(Earth-616)	No Dual Identity	Good Characters	Bald	C
16373	695217	Tinkerer (Skrull) (Earth-616)	VTinkerer_(Skrull)_(Earth-616)	Secret Identity	Bad Characters	Bald	C
16374	708811	TK421 (Spiderling) (Earth-616)	VTK421_(Spiderling)_(Earth-616)	Secret Identity	Neutral Characters	NaN	C
16375	673702	Yologarch (Earth-616)	VYologarch_(Earth-616)	NaN	Bad Characters	NaN	

16373 rows × 11 columns

В столбце 'APPEARANCES' больше нет пропущенных данных:

```
In [169]: data.isnull().sum()
```

```
Out[169]: page_id      0
          name         0
          urlslug      0
          ID        3767
          ALIGN       2809
```

```
HAIR          4261
SEX           851
ALIVE         0
APPEARANCES   0
FIRST APPEARANCE 812
Year          812
dtype: int64
```

## Обработка пропусков в категориальных данных

```
In [170]: # Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count > 0 and (dt == 'object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка { }. Тип данных { }. Количество пустых значений { }, { }%'.format(col, dt, temp_n
ull_count, temp_perc))
```

Колонка ID. Тип данных object. Количество пустых значений 3767, 23.0%.

Колонка ALIGN. Тип данных object. Количество пустых значений 2809, 17.15%.

Колонка HAIR. Тип данных object. Количество пустых значений 4261, 26.02%.

Колонка SEX. Тип данных object. Количество пустых значений 851, 5.2%.

Колонка FIRST APPEARANCE. Тип данных object. Количество пустых значений 812, 4.96%.

```
In [171]: cat_temp_data = data[['SEX']]
cat_temp_data.head()
```

Out[171]:

	SEX
0	Male Characters
1	Male Characters
2	Male Characters
3	Male Characters
4	Male Characters

```
In [172]: cat_temp_data['SEX'].unique()
```

```
Out[172]: array(['Male Characters', 'Female Characters', 'Genderfluid Characters',
                'Agender Characters', nan], dtype=object)
```

```
In [173]: cat_temp_data[cat_temp_data['SEX'].isnull()].shape
```

```
Out[173]: (851, 1)
```

```
In [174]: # Импутация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

```
Out[174]: array(['Male Characters'],
```

```
['Male Characters'],
['Male Characters'],
...,
['Male Characters'],
['Male Characters'],
['Male Characters']], dtype=object)
```

```
In [175]: # Пустые значения отсутствуют
np.unique(data_imp2)
```

```
Out[175]: array(['Agender Characters', 'Female Characters',
'Genderfluid Characters', 'Male Characters'], dtype=object)
```

## 2. Преобразование категориальных признаков в числовые

```
In [176]: cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

```
Out[176]:
```

	c1
0	Male Characters
1	Male Characters
2	Male Characters
3	Male Characters
4	Male Characters
...	...
16368	Male Characters
16369	Male Characters
16370	Male Characters
16371	Male Characters
16372	Male Characters

16373 rows × 1 columns

## Кодирование категорий целочисленными значениями - label encoding

```
In [177]: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

```
In [178]: le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

```
In [179]: cat_enc['c1'].unique()
```

```
Out[179]: array(['Male Characters', 'Female Characters', 'Genderfluid Characters',
'Agender Characters'], dtype=object)
```

```
In [180]: np.unique(cat_enc_le)
```

```
Out[180]: array([0, 1, 2, 3])
```

```
In [181]: le.inverse_transform([0, 1, 2, 3])
```

```
Out[181]: array(['Agender Characters', 'Female Characters',  
                'Genderfluid Characters', 'Male Characters'], dtype=object)
```


### 3. Масштабирование данных

```
In [184]: from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

```
In [188]: sc1 = MinMaxScaler()  
sc1_data = sc1.fit_transform(data[['Year']])
```

```
In [189]: plt.hist(data['Year'], 50)  
plt.show()
```

```
c:\users\user\appdata\local\programs\python\python37-32\lib\site-package  
s\numpy\lib\histograms.py:839: RuntimeWarning: invalid value encountered  
in greater_equal  
    keep = (tmp_a >= first_edge)  
c:\users\user\appdata\local\programs\python\python37-32\lib\site-package  
s\numpy\lib\histograms.py:840: RuntimeWarning: invalid value encountered  
in less_equal  
    keep &= (tmp_a <= last_edge)
```



```
In [190]: plt.hist(sc1_data, 50)  
plt.show()
```

